Nama: Rafael Nicholas Tanaja

NIM: 2540118656

## **Code Questions**

## Number 1

```
scala> import org.apache.spark.sql
import org.apache.spark.sql
scala> import spark.implicits._
import spark.implicits._
```

```
scala> spark.sql("USE hr_db")
res7: org.apache.spark.sql.DataFrame = []
scala> spark.sql("show tables from hr_db").show()
+-----+
|database| tableName|isTemporary|
+-----+
| hr_db|hr_records| false|
+-----+
```

```
scala> df.show(15)
first_name|count|rank|
      Fidel|
              253
                      2
3
4
5
      Ralph
              252
       Otis
              250
              250
   Terrance|
       0tha
              249
              247
      Lamar
                      6
     Efrain|
              246
                      7
     Alvaro
              244
       Phil
                      8
              243
                      8
     Walker
              243
                      9
      Keith|
              242
                      9
              242
       Amos
                      9
              242
      Myron
                      9
      Luigi
              242
   Garfield|
              241
                     10
only showing top 15 rows
```

```
scala> val row = df.count()
row: Long = 1219
```

scala> df.write.format("csv").mode("overwrite").option("header", false).option("sep","-").save("/user/2540118656/solution")

```
scala> val test123 = spark.read.format("csv").option("header", "false").load("/user/2540118656/solution/")
test123: org.apache.spark.sql.DataFrame = [_c0: string]
scala> test123.show(15)
            _c0|
    Fidel-253-1|
     Ralph-252-2
     Otis-250-3
 Terrance-250-3
     Otha-249-4
    Lamar-247-5
   Efrain-246-6
   Alvaro-244-7
     Phil-243-8
   Walker-243-8
    Keith-242-9
     Amos-242-9
    Myron-242-9
    Lúigi-242-9
 Garfield-241-10
only showing top 15 rows
```

```
scala> val emrdata = spark.read.parquet("/user/verulam_blue/data/emr_data")
emrdata: org.apache.spark.sql.DataFrame = [extract_date: date, date_of_visit: date ... 4 more fields]
scala> emrdata.show(5)
 extract_date|date_of_visit|mod_zcta|total_ed_visits|ili_pne_visits|ili_pne_admissions|
  2020-07-25
                2020-07-14
                             11420
                                              27
  2020-07-25
                2020-07-02
                             10038
  2020-07-24
               2020-05-31
                             10019
                                              33
  2020-07-25
              2020-03-01
                            11210
                                              70
              2020-06-28 11223
  2020-07-25
                                              43
only showing top 5 rows
```

scala> emrdata.createOrReplaceTempView("emrdata1")

scala> emr.write.format("csv").mode("overwrite").option("header", false).option("sep", "\t").save("/user/2540118656/solution")

## Number 3

```
scala> val gprx = spark.sql("SELECT * FROM gp_rx")
gprx: org.apache.spark.sql.DataFrame = [sha: string, pct: string ... 8 more fields]
scala> val gpaddress = spark.sql("SELECT * FROM gp_address")
gpaddress: org.apache.spark.sql.DataFrame = [date: string, practice_code: string ... 6 more fields]
```

```
scala> gprx.show(5)
                                                    bnf_name|items| nic|act_cost|quantity|period|
                              bnf_code|
 sha|pct|practice_code|
 044 | RJN |
                Y05218|0501013K0AAAJAJ|Co-Amoxiclav_Tab ...|
                                                                  1 3.59
                                                                              3.331
                                                                                          21 | 201512 |
 Q44 | RJN |
                Y05218|0501130R0AAAAAA|Nitrofurantoin_Ca...|
                                                                  1|14.39|
                                                                             13.42
                                                                                          28 | 201512 |
 044 | RTV |
                                            Diazepam_Tab 2mg
                                                                  1 0.51
                                                                                         14 201512
                Y04937|0401020K0AAAHAH|
                                                                              0.581
 044 | RTV |
                Y04937 0401020P0AAABAB Lorazepam_Tab 1mg
                                                                  1 2.65
                                                                              2.46
                                                                                          28 | 201512 |
 044 | RTV |
                Y04937 O402010ABAAABAB Quetiapine_Tab 25mg
                                                                  2 | 2.01 |
                                                                              2.08
                                                                                          84 | 201512 |
only showing top 5 rows
scala> gpaddress.show(5)
                                                                      address_2
                                                                                       address 3|address 4|postcode|
   date|practice_code|
                              surgery_name|
                                                       address_1|
 201512
               A81001| THE DENSHAM SURGERY| THE HEALTH CENTRE|LAWSON STREET|STOCKTON ON TEES|CLEVELAND|TS18 1HU|
               A81002 QUEENS PARK MEDIC... QUEENS PARK MEDIC... FARRER STREET STOCKTON ON TEES CLEVELAND TS18 2AW
 201512
 2015121
               A81003|VICTORIA MEDICAL ...
                                               THE HEALTH CENTRE|VICTORIA ROAD|
                                                                                      HARTLEPOOL | CLEVELAND | TS26 8DB |
               A81004|WOODLANDS ROAD SU...
                                                6 WOODLANDS ROAD
 201512
                                                                                    MIDDLESBROUGH|CLEVELAND| TS1 3BE
 201512
               A81005 | SPRINGWOOD SURGERY
                                              SPRINGWOOD SURGERY | RECTORY LANE
                                                                                      GUISBOROUGH
                                                                                                            |TS14 7DJ|
only showing top 5 rows
```

```
scala> gprx.createOrReplaceTempView("gprx1")
scala> gpaddress.createOrReplaceTempView("gpaddress1")
```

```
scala> gp.write.mode("overwrite").json("/user/2540118656/solution")
scala> val test123 = spark.read.json("/user/2540118656/solution")
test123: org.apache.spark.sql.DataFrame = [nbr_prescriptions: bigint, practice_code: string ... 1 more field]
scala> test123.show(false)
|nbr_prescriptions|practice_code|surgery_name
2267
                   Y03641
                                 |BOLTON COMMUNITY DRUG AND ALCOHOL SERV|
165
                   Y00747
                                 |HALLIWELL HEALTH & CHILDREN'S CENTRE
 9081
                   P82018
                                 THE ALASTAIR ROSS MEDICAL PRACTICE
                   P82607
 9392
                                 WALMSLEY-CROMPTON HEALTH CENTRE
                   Y02943
                                 NEUROLOGY LONG TERM CONDITIONS
 56
6191
                   P82036
                                 LITTLE LEVER HEALTH CENTRE 2
8710
                   P82021
                                 KIRBY-CROMPTON HEALTH CENTRE
                                 LITTLE LEVER HEALTH CENTRE 1
 6896
                   P82020
 5360
                   P82633
                                 GREAT LEVER HEALTH CENTRE 1
                   P82624
6108
                                 ORIENT HOUSE MEDICAL CENTRE
10541
                   P82613
                                 SPRING VIEW MEDICAL CENTRE
22209
                   Y03079
                                 BOLTON COMMUNITY PRACTICE
                                 SWAN LANE MEDICAL CENTRE
15775
                   P82004
70
                   Y00215
                                 ORTHOPAEDIC & RHEUMATOLOGY
2618
                   P82625
                                 CHARLOTTE STREET SURGERY
 12220
                   P82023
                                 MANDALAY MEDICAL CENTRE
                   P82011
9111
                                 TONGE FOLD HEALTH CENTRE
14147
                   P82009
                                 ST HELENS ROAD PRACTICE
18419
                   P82001
                                 THE DUNSTAN PARTNERSHIP
```

**Essay Question** 

1. Situasi ini dapat terjadi pada broadcast table yang terlalu besar untuk masuk ke dalam

memori. Terdapat beberapa cara yang dapat dilakukan seperti mengurangi ukuran broadcast

table, menggunakan metode join lainnya, menggunakan sampling techniques, atau

menambahkan jumlah memori.

2. Adaptive Query Execution merupakan fitur di dalam Spark untuk query merubah eksekuusi

dari query secara dinamis berdasarkan distribusi data dan resources. Dengan AQE, query

optimizer dapat mendeteksi secara otomatis dan mengatasi data distribusi yang skew. Fitur

ini dapat membantu developer untuk melakukan partition coalescing secara otomatis. Fitur

ini juga membuat query development menjadi lebih efisien dan mengurangi terjadinya

error.

Reference: https://www.databricks.com/blog/2020/05/29/adaptive-query-execution-

speeding-up-spark-sql-at-runtime.html

3. Data Source: Bagian ini merupakan tempat untuk mengambil data. Jika menggunakan CSV

maka akan diambil melalui File Source.

Processing Logic: Di dalam bagian ini merupakan bagian dimana user akan mendefinisikan

operasi yang akan dilakukan kepada data.

Output Mode: Pada Output Mode, akan mengeluarkan hasil query yang akan ditulis ke

dalam sink.

Trigger: Pada Trigger, bagian ini merupakan tempat mengontrol kapan akan mengeksekusi

processing logic pada streaming, seperti akan menghentikan operasi jika jumlah data sudah

terpenuhi atau saat waktu yang ditentukan telah selesai.

Data Sink: Bagian ini berguna untuk menyimpan hasil output dari streaming application.

Pada kasus ini akan disimpan pada file sink dalam bentuk CSV.